Proyecto estadísticas de YouTube Avances IV

Informe de resultados y reflexión · Semana 10

Cristian Camilo Alarcon Delgadillo

Bryan Arley Saenz Cortes

Jonathan David Lancheros Bello

Universidad de Cundinamarca

Especialización en Inteligencia Artificial

Procesamiento de Lenguaje Natural

Paul Alexander Diaz Montaña

24 de octubre de 2026

Resumen

Este informe cierra el proyecto de estadísticas de YouTube mediante una comparación entre el diseño de referencia del curso, los avances anteriores y los resultados finales. Se conserva una base de 1.867 videos y 18.159 comentarios. El ensamble elegido en Avances III combina boosting tabular y regresión Ridge con TF-IDF del título y los comentarios. Sin realizar una nueva selección, se evaluó el artefacto congelado en los 374 videos de la prueba conocida de Avances II. En la evaluación local inicial se obtuvo RMSE de 0,5593, MAE de 0,4214 y R^2 de 0,9461 en la escala ln(1 + vistas). La reducción descriptiva del RMSE frente a HGB fue del 4,08 %, pero el intervalo bootstrap apareado de la diferencia incluyó cero. En un estrés interno por fecha de publicación, HGB superó al ensamble, lo que limita la generalización del orden observado. Las verificaciones de software comprobaron equivalencia en 50 casos, rechazo de seis entradas inválidas e inferencia local de baja latencia. Se entregan el repositorio, los cuadernos y las capturas reales. La reproducción en Google Colab, mediante su extensión oficial para VS Code, completó cinco celdas y conservó la precisión del modelo congelado. El producto estima popularidad contemporánea y no acredita un pronóstico futuro ni efectos causales del lenguaje. Se analizan retos, soluciones, aprendizajes y el alcance verificable de la colaboración.

Palabras clave: YouTube, procesamiento de lenguaje natural, evaluación, reproducibilidad, popularidad.

Propósito y diseño de referencia

La actividad Avances IV solicita contrastar los resultados con el diseño inicial, explicar los retos y soluciones, identificar lecciones y reflexionar sobre el trabajo colaborativo, con un informe PDF y acceso al proyecto en GitHub y Google Colab (Universidad de Cundinamarca, 2026). El referente de diseño disponible es la orientación de REA 2 y la continuidad documentada de Avances II y III. No se dispone de un documento formal de Avances I; por ello, no se le atribuyen decisiones ni metas numéricas que no puedan comprobarse.

El propósito del proyecto fue explorar cómo los comentarios y otras señales de interacción se relacionan con el rendimiento de los videos, construir un modelo útil y llevarlo a una interfaz de consulta. El alcance operativo se precisó como estimación de vistas acumuladas a partir de información ya observada. Esta definición es esencial: likes y comentarios también se acumulan con las vistas, de modo que una asociación predictiva contemporánea no demuestra que los comentarios produzcan más visualizaciones.

La pregunta final es si la incorporación de lenguaje y la combinación de modelos aportan una mejora suficientemente sustentada frente a la referencia tabular, y qué condiciones faltan para un uso más amplio. Se evalúan por separado calidad predictiva, integridad del software, reproducibilidad y madurez de despliegue. Ninguna de esas dimensiones sustituye a las otras.

Resultados frente al diseño inicial

Tabla 1

Contraste entre el diseño de referencia y el producto obtenido

Dimensión	Resultado verificable	Balance
Datos de videos y comentarios	1.867 videos únicos y 18.159 comentarios depurados; descarga y hashes verificables.	Alcanzado en la muestra histórica.
Aporte del lenguaje	TF-IDF real de comentarios y títulos; variantes de texto aislado, tabular y combinado.	Implementado; aporte condicionado por interacciones.
Modelo de rendimiento	HGB de referencia y ensamble congelado con métricas y diagnóstico por segmentos.	Estimación contemporánea; sin pronóstico validado.
Interfaz utilizable	Prototipo de Avances III con inferencia portable, validación y monitoreo local.	Prototipo; acceso restringido y sin servicio productivo central.
Infraestructura en nube	Interfaz desplegada y cinco celdas ejecutadas en un servidor de Google Colab.	Reproducción remota con salidas y entorno guardados.
MLOps y seguimiento	Artefacto identificado, casos de paridad, resultados versionables y contrato de entrada.	Faltan deriva, alertas y seguimiento central con datos nuevos.
Trabajo colaborativo	Tres autores confirmados; continuidad de informes y repositorio de una cuenta.	Sin atribución individual sustentada ni actas de revisión.

Nota. El balance distingue producto implementado, evidencia disponible y validación pendiente. No convierte una funcionalidad de prototipo en una capacidad de producción.

La principal modificación de alcance fue hacer explícito que el conjunto disponible permite estudiar popularidad observada, pero no medir crecimiento futuro. Esta delimitación evita prometer una capacidad que requeriría capturas sucesivas y un horizonte temporal definido.

Evolución y cambios de implementación

Tabla 2

Continuidad de las etapas y fundamento de los cambios

Etapa	Decisión y resultado	Justificación
Avances II	Seis alternativas y 19 configuraciones; HGB: RMSE de validación 0,6218 y de prueba 0,5831.	Construir una referencia y detectar redundancia del total Comments.
Avances III	Nueve alternativas y 16 configuraciones; validación anidada 5 × 3 en 1.493 videos.	Separar la búsqueda actual de su evaluación; excluir la prueba ya conocida.
Selección III	Ensamble HGB sin Comments y Ridge con título más comentarios; pesos 50/50 en log.	Combinar patrones no lineales e información léxica sin ajustar pesos con la prueba.
Avances IV	Evaluación retrospectiva del artefacto congelado; bootstrap apareado y estrés por publicación.	Examinar magnitud, incertidumbre y sensibilidad del resultado final.
Verificación IV	Inferencia JSON sin pickle; 50 casos de paridad, seis entradas inválidas y latencia.	Comprobar que el producto ejecuta el modelo esperado y controla entradas.

Nota. Los valores de II y III son antecedentes documentales (Alarcon Delgadillo et al., 2026a, 2026b). La evaluación IV fue ejecutada el 24 de octubre de 2026.

El cambio no consistió en añadir complejidad por sí misma. Se mantuvieron modelos compatibles con el tamaño de la muestra y se probaron hipótesis concretas: simplificación de predictores, información textual adicional y combinación de errores. El modelo de texto aislado se conserva como contraste, incluso cuando su precisión es menor.

Datos, variables y protocolo final

La fuente es YouTube Statistics, de Patil (s. f.). Los archivos originales contienen 1.881 videos y 18.409 comentarios. Se retiraron 12 repeticiones por Video ID y dos videos sin objetivo; en comentarios se retiró un texto ausente y 249 repeticiones por video y texto. Los conteos negativos de likes y comentarios se trataron como faltantes. La base final contiene 41 palabras clave, seis likes ausentes y dos totales de comentarios ausentes. Las claves temáticas no equivalen a categorías oficiales uniformes de toda la plataforma.

Cada unidad de evaluación es un video. Los comentarios se agregan por identificador antes de la partición. El objetivo es $y = \ln(1 + \text{Views})$. Los predictores incluyen conteos transformados, edad histórica al 24 de agosto de 2022, forma del título, palabra clave y representaciones del texto. TF-IDF utiliza unigramas y bigramas, frecuencia sublineal, min_df = 3 y hasta 3.000 términos. Las transformaciones aprendidas se conservan dentro de los estimadores; Views e identificadores no son predictores.

Se reproduce la partición aleatoria con semilla 42: 1.493 videos de desarrollo y 374 de prueba conocida. El ensamble y el modelo de texto se cargan congelados desde III. HGB se reajusta exclusivamente con desarrollo como referencia fija de II. No se busca una configuración nueva con los 374 casos. Aun así, estos resultados son retrospectivos: la prueba ya informó el proceso anterior y no debe presentarse como una muestra externa independiente. La separación entre selección y evaluación sigue el principio metodológico descrito por Scikit-learn (s. f.).

Evaluación retrospectiva del modelo congelado

Tabla 3

Desempeño en los 374 videos de la prueba conocida

Modelo	RMSE log	MAE log	R^2 log	MAE vistas (M)	RMSE vistas (M)
Ensamble congelado III	0,5593	0,4214	0,9461	11,33	174,33
Solo comentarios congelado III	2,1017	1,6817	0,2391	17,78	213,87
HGB referencia II	0,5831	0,4411	0,9414	13,26	195,28
Mediana	2,4168	1,9660	-0,0062	17,96	213,94

Nota. M = millones. Conversión de predicciones: max(0, exp(ŷ) - 1), sin corrección de sesgo. Fuente: retrospective_metrics.csv. Menor RMSE o MAE es mejor; mayor R^2 es mejor.

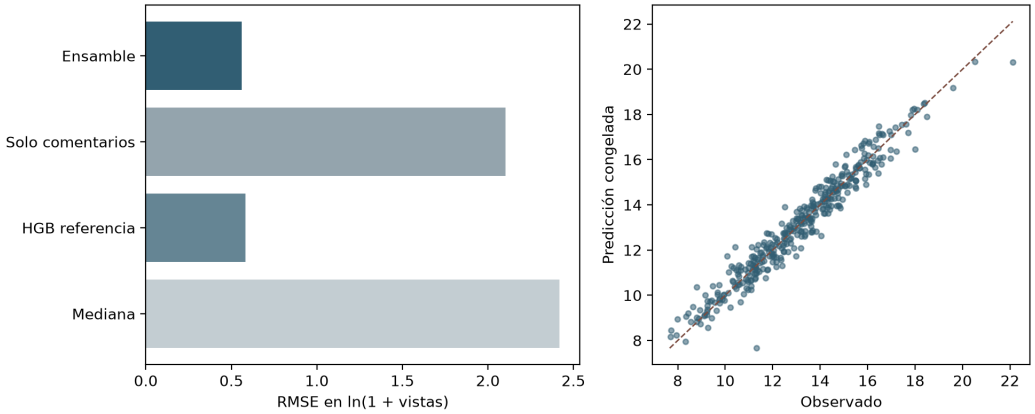
El ensamble redujo descriptivamente el RMSE log de 0,5831 a 0,5593 frente a HGB, una diferencia de -0,0238 y una reducción relativa de 4,08 %. El MAE descendió de 0,4411 a 0,4214. En la escala original, el MAE pasó de 13,26 a 11,33 millones de vistas y el RMSE de 195,28 a 174,33 millones. La mejora se observa en las dos escalas, pero el error absoluto sigue siendo elevado para un uso que exija conteos precisos en videos virales.

Solo comentarios obtuvo $R^2 = 0,2391$ y RMSE = 2,1017. Supera a la mediana, pero queda lejos de los modelos que usan señales de interacción. Esto respalda una utilidad complementaria del texto bajo este diseño; no prueba que el lenguaje por sí solo explique el rendimiento ni que una emoción particular cause popularidad. El R^2 de 0,9461 describe variación del objetivo logarítmico en esta muestra; no equivale a un porcentaje de exactitud de vistas individuales.

Diagnóstico visual y errores por popularidad

Figura 1

Comparación de modelos y predicciones retrospectivas



Nota. Cada punto representa uno de los 374 videos. La diagonal indica coincidencia ideal. Elaboración propia a partir de las predicciones guardadas.

Tabla 4

Error del ensamble por cuartil de vistas observadas

Grupo	n	MAE log	MAE vistas	R^2 log
Q1	94	0,4198	16.922	0,6748
Q2	93	0,4356	99.519	-0,2595
Q3	93	0,3763	528.024	-0,0358
Q4	94	0,4535	44.458.711	0,7967

Nota. Q1 contiene los videos con menos vistas y Q4 los de más vistas dentro de la prueba conocida. Los cuartiles se usan para diagnóstico posterior, no como entradas del modelo.

El MAE en log varía entre 0,3763 y 0,4535, pero el MAE original de Q4 alcanza 44,46 millones de vistas. Los R^2 negativos de Q2 y Q3 no contradicen el R^2 global: al restringir el rango, disminuye la variación con la que se compara el error. El desempeño agregado puede ocultar debilidades locales.

Incertidumbre y prueba de estrés

Con 2.000 remuestreos percentiles de pares observados y predichos, el intervalo del 95 % para RMSE del ensamble fue [0,4934; 0,6361]. El bootstrap apareado de la diferencia ensamble menos HGB produjo [-0,0535; 0,0015]. Como incluye cero, la mejora puntual no basta para afirmar superioridad concluyente. Se mantienen fijas las predicciones; no se repite el entrenamiento ni se corrige dependencia por canal, por lo que estos intervalos no cubren todas las fuentes de incertidumbre ni son intervalos de predicción individual.

Tabla 5

Estrés interno según fecha de publicación

Modelo	RMSE log	MAE log	R^2 log
HGB fijo	0,7023	0,5453	0,8258
Ensamble fijo	0,7497	0,5971	0,8015
Texto fijo alpha 10	3,3100	2,9899	-2,8697

Nota. Orden estable por Published At: 1.493 videos más antiguos para ajustar y 374 más recientes para evaluar; la fecha mínima del bloque reciente es 23/08/2022. Recetas fijas, sin nueva búsqueda.

En este corte HGB obtuvo RMSE de 0,7023 y el ensamble 0,7497: el ensamble fue 6,76 % peor en RMSE. La inversión del orden muestra sensibilidad al régimen de evaluación. No constituye validación temporal externa: son datos del mismo conjunto histórico, la selección de recetas ocurrió antes sobre ese conjunto y la fecha de publicación no identifica el momento de captura de likes, comentarios y vistas. Tampoco permite estimar vistas a siete o treinta días.

Retos metodológicos y soluciones

Tabla 6

Problemas, respuesta aplicada y evidencia de su alcance

Reto	Solución y fundamento	Evidencia y límite
Prueba ya conocida	Congelar el artefacto y distinguir evaluación retrospectiva de validación anidada anterior.	Sin nueva búsqueda en IV; aún falta una muestra independiente.
Redundancia y señales contemporáneas	Ablación de Comments y combinación de HGB con Ridge textual.	Mejora puntual en prueba conocida; el orden se invierte por publicación.
Cola de vistas muy asimétrica	Objetivo log, métricas en ambas escalas y diagnóstico por cuartiles.	Q4 mantiene MAE de 44,46 M; hace visible el costo en casos virales.
Comentarios multilingües y etiquetas ambiguas	TF-IDF sin lista exclusiva de stopwords en inglés; códigos de sentimiento sin reinterpretación emocional.	Representación reproducible; no hay evaluación semántica humana ni causal.
Datos incompletos y duplicados	Unión por video, depuración de repetidos e imputación aprendida en entrenamiento.	Conteos auditados; elegir primera aparición no garantiza registro más reciente.

Nota. Las soluciones responden a problemas observados. Una mejora de control metodológico no elimina restricciones de muestreo ni sustituye nuevos datos.

La innovación aplicada es la integración de evaluación, diagnóstico y contrato de inferencia con un artefacto identificable, más que la invención de un algoritmo nuevo. Esta decisión hace posible revisar qué se midió, con qué versión y bajo qué supuestos.

Retos de implementación y verificación

Tabla 7

Comprobaciones ejecutadas sobre la inferencia local

Comprobación	Resultado	Interpretación
Paridad con el artefacto III	50 casos; error máximo log 3,55 × 10^-15; tolerancia 10^-8.	Equivalencia numérica en los casos guardados; no es validación predictiva adicional.
Contrato de entrada	6 de 6 entradas inválidas rechazadas.	Incluye negativos, NaN, infinito, texto vacío, título excesivo y booleano numérico.
Inferencia repetida	100 consultas; mediana 8,72 ms; percentil 95 de 16,12 ms.	Medición local de CPU; excluye red, arranque y concurrencia.
Persistencia portable	JSON comprimido, sin carga de objetos pickle.	Transformaciones, coeficientes y árboles explícitos; requiere conservar el exportador correcto.

Nota. Resultados de verification.json; las latencias corresponden a la ejecución inicial local del 24/10/2026 y pueden variar entre equipos.

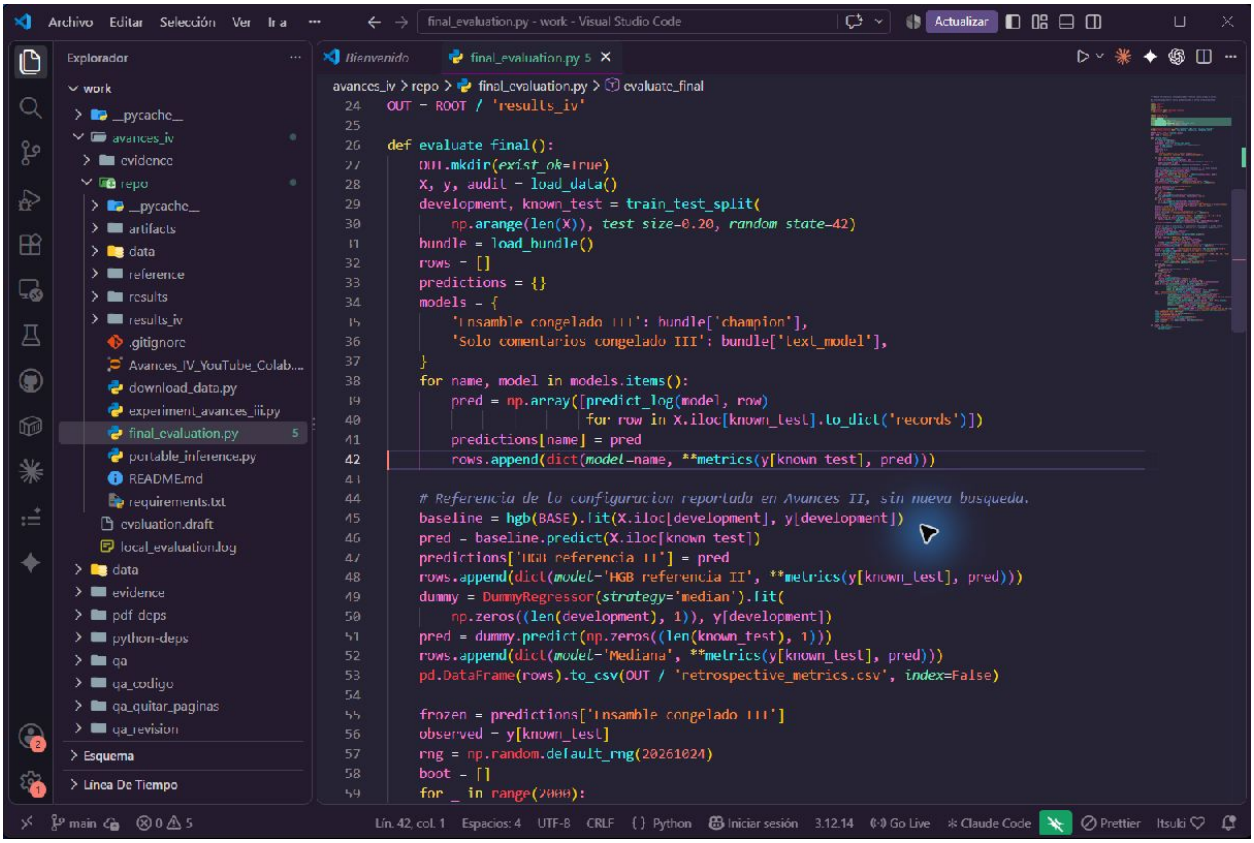
La portabilidad se resolvió reconstruyendo imputación, escala, categorías, TF-IDF y predicción desde el artefacto exportado. Los casos de paridad permiten detectar divergencias numéricas antes de cambiar la interfaz. El costo es mantener una implementación de inferencia adicional; cada cambio de representación exige exportar de nuevo el artefacto y volver a verificarlo.

La validación de entrada reduce fallos de uso, pero no detecta por sí sola datos fuera de distribución. Una consulta con números válidos puede ser muy distinta de los videos históricos. El monitoreo del prototipo registra actividad en el navegador; carece de un sistema central que contraste predicciones con vistas posteriores, supervise deriva o active alertas operativas.

Evidencia del desarrollo en Visual Studio Code

Figura 2

Carga del modelo congelado y comparación con la referencia



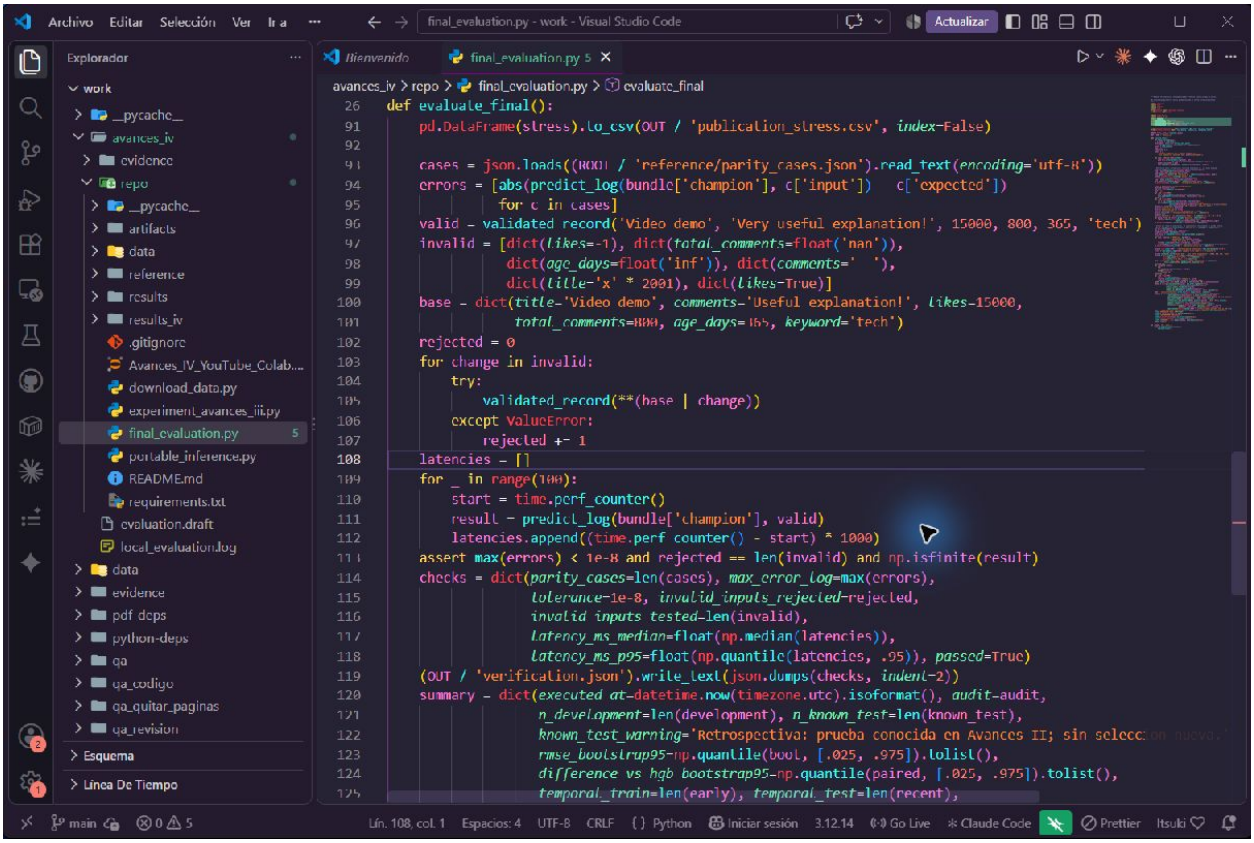
Nota. Captura real de VS Code en el equipo de trabajo, 24/10/2026. final_evaluation.py, líneas 24-59. Se observan la separación fija, la carga del artefacto y el cálculo de métricas.

El bloque mostrado evita reajustar el ensamble al leer la prueba conocida: sus predicciones se obtienen del modelo guardado. La referencia HGB utiliza únicamente los índices de desarrollo. Guardar las predicciones por video permite reconstruir diagnósticos, no solo conservar una cifra final. La captura aporta contexto del código; los archivos fuente y resultados completos son la evidencia reproducible.

Evidencia de las verificaciones de software

Figura 3

Paridad, entradas inválidas y latencia en el código



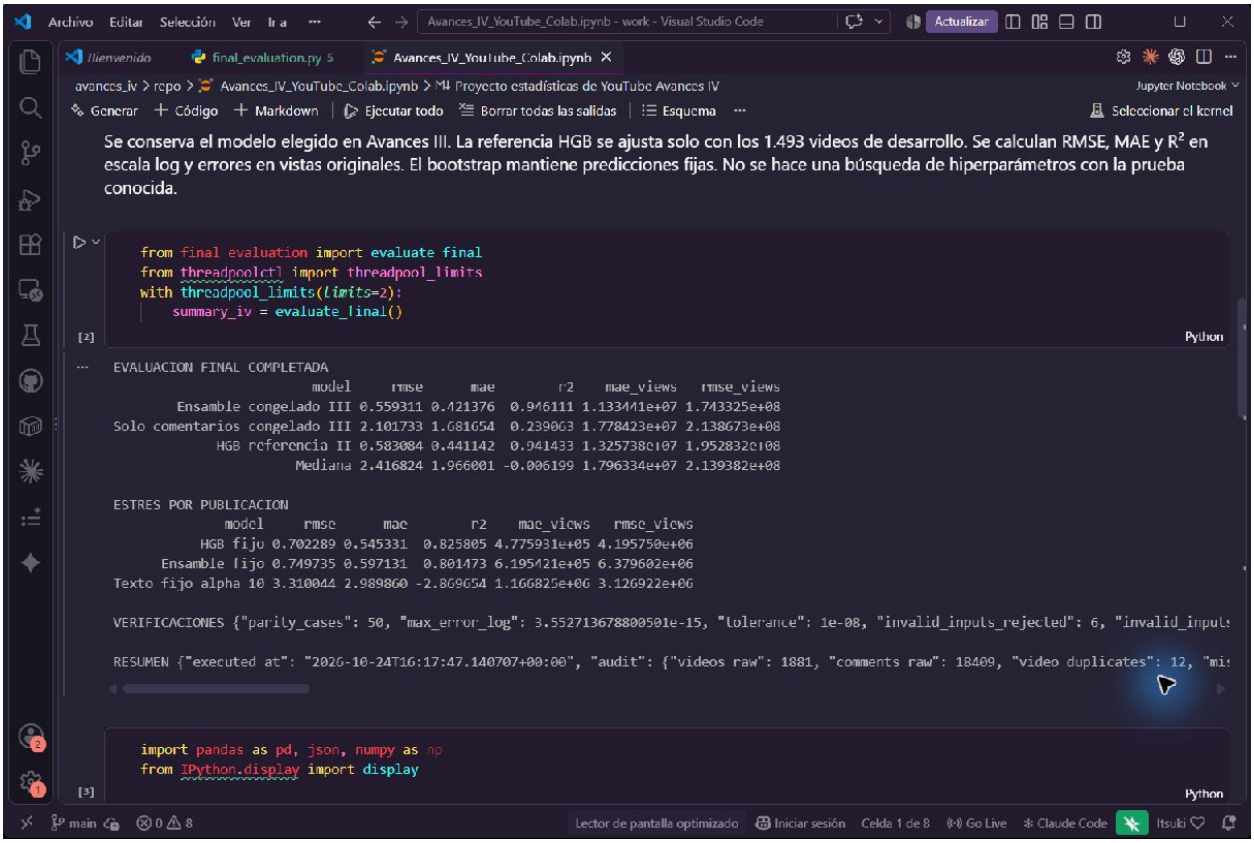
Nota. Captura real de VS Code en el equipo de trabajo, 24/10/2026. final_evaluation.py, líneas 91-125. No es una representación recreada del editor.

El programa compara las predicciones portables con los casos de referencia, prueba seis entradas inválidas y mide cien inferencias. Una aserción detiene la ejecución si se incumple la tolerancia, no se rechazan todos los casos o aparece un resultado no finito. Estas verificaciones cubren rutas concretas del software y deben ampliarse antes de exponer un servicio con usuarios concurrentes.

Reproducción del cuaderno en Visual Studio Code

Figura 4

Salidas de la evaluación final en el cuaderno ejecutado



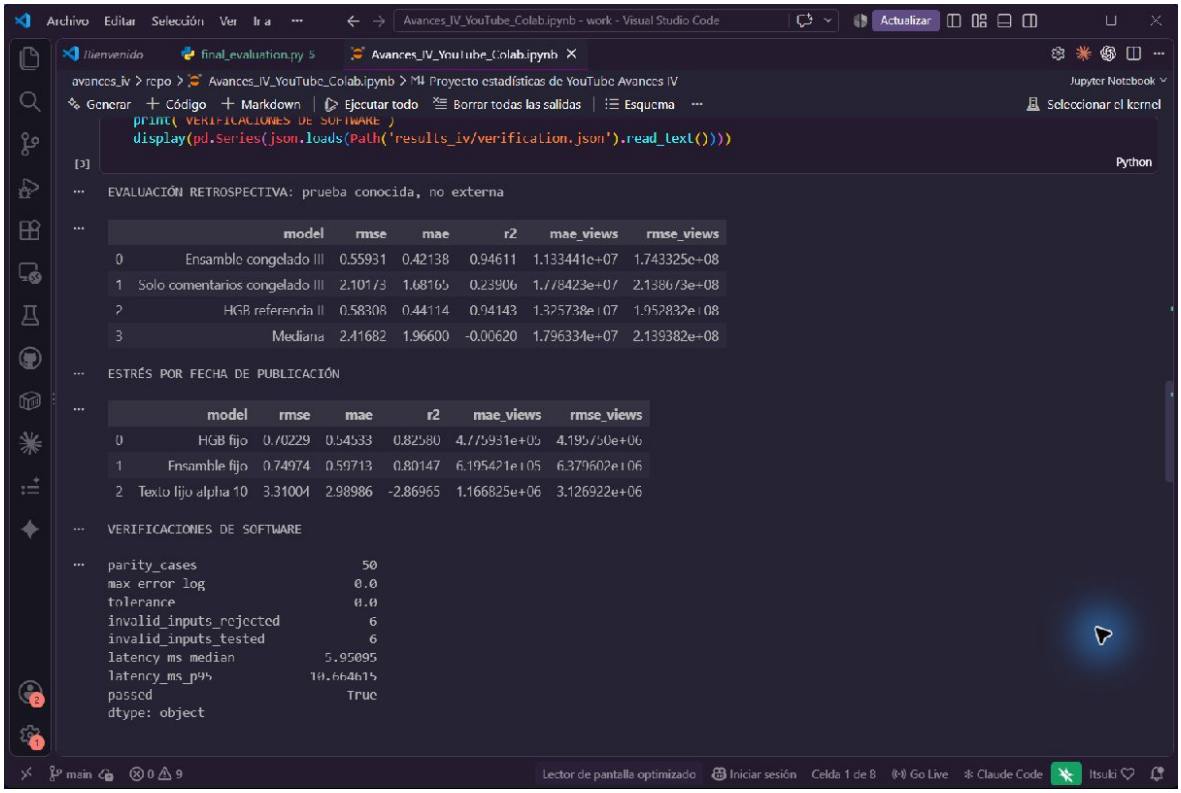
Nota. Captura real del cuaderno abierto en VS Code, 24/10/2026. Se observan las métricas de la ejecución con Python local. La visualización en este editor no se atribuye a una ejecución en Google Colab.

El cuaderno conserva el código y las salidas de sus cinco celdas ejecutables. La primera salida identifica Python local y verifica los hashes de los dos archivos de entrada. Las siguientes registran la evaluación, los cuadros de resultados, la figura y la exportación de resultados. Las cifras coinciden con la evaluación local inicial; la latencia depende de cada ejecución. El enlace de Colab permite abrir esta misma estructura para repetirla en el servicio, sin confundir el formato del cuaderno con el lugar donde se realizó la verificación.

Lectura de los resultados del cuaderno

Figura 5

Cuadros de evaluación y verificaciones del notebook



Nota. Captura real del archivo .ipynb en VS Code. La presentación redondea valores pequeños de la serie; verification.json conserva la precisión completa. Las latencias corresponden a la repetición del cuaderno y pueden diferir de la ejecución inicial de la Tabla 7.

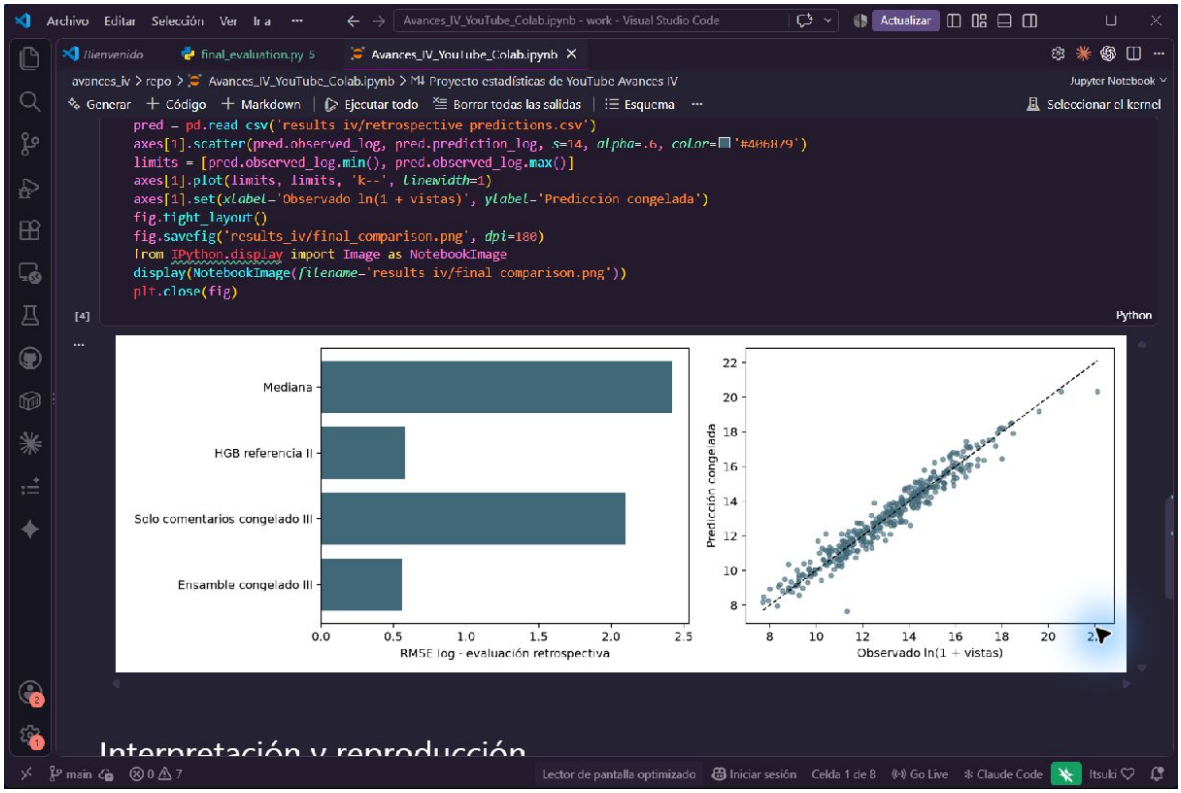
El primer cuadro compara los cuatro modelos sobre la misma prueba conocida. Las columnas rmse, mae y r2 usan el objetivo logarítmico; mae_views y rmse_views expresan errores en vistas. El segundo cuadro cambia la separación a fecha de publicación y muestra que el orden de los modelos no es estable. Por eso se interpretan ambos escenarios, en lugar de elegir únicamente la tabla más favorable.

La salida inferior comprueba 50 casos de paridad y seis rechazos de entradas inválidas. El valor passed = True confirma esas aserciones de software; no significa que todas las predicciones sean correctas ni que exista una validación externa.

De las predicciones a la visualización

Figura 6

Código de visualización y figura producida en el cuaderno



Nota. Captura real de la celda ejecutada y su salida. El código lee retrospective_predictions.csv, dibuja la referencia diagonal y guarda final_comparison.png. La figura compara resultados retrospectivos, sin medir crecimiento futuro.

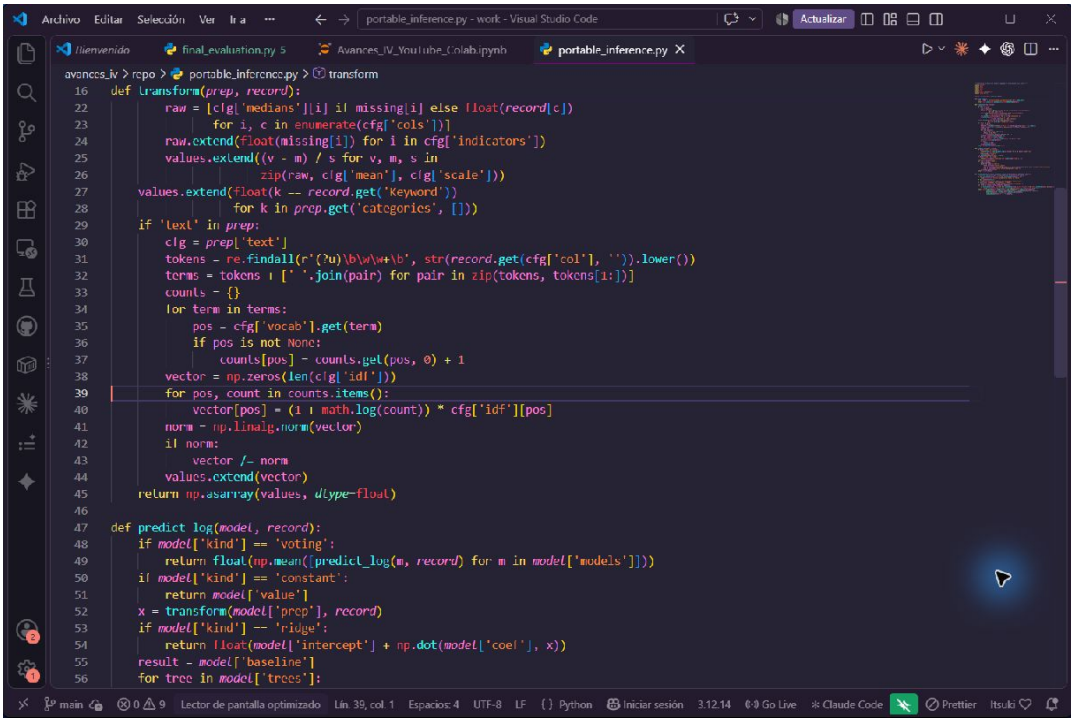
El panel izquierdo resume RMSE: una barra más corta indica menor error en log. El panel derecho permite revisar cada video. Los puntos por debajo de la diagonal representan subestimación y los que quedan por encima representan sobreestimación. La concentración cerca de la recta muestra ajuste global, mientras los puntos alejados revelan casos que una sola métrica puede ocultar.

La imagen conecta el archivo de predicciones con el diagnóstico visual y permite reconstruirlo. Se conserva la escala logarítmica para observar también videos pequeños; los errores absolutos en vistas se examinan por separado en las Tablas 3 y 4.

Cómo se utiliza el texto en la inferencia

Figura 7

Transformación léxica y combinación de predicciones



Nota. Captura real de portable_inference.py en VS Code, líneas 22-56. Se observan el vocabulario congelado, la ponderación TF-IDF, la normalización y el inicio de la predicción. Esta rutina aplica parámetros aprendidos en III; no vuelve a entrenar con la consulta.

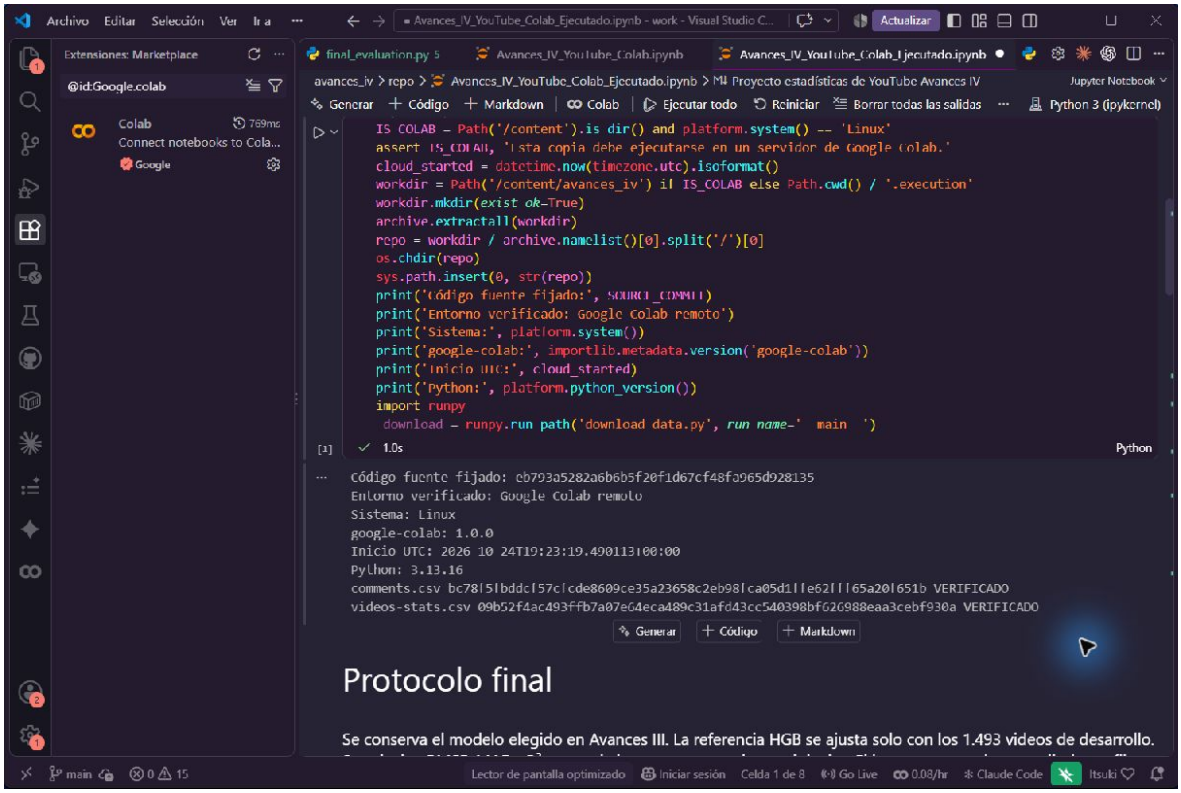
El bloque convierte el texto a minúsculas, extrae palabras de al menos dos caracteres y construye bigramas consecutivos. Cada término se busca en el vocabulario guardado; los términos nuevos se ignoran. Las frecuencias reciben la ponderación sublineal 1 + ln(conteo), se multiplican por el IDF almacenado y se normalizan con la norma L2. Así se reproduce la representación usada por Ridge.

En predict_log, Ridge calcula intercepto más producto de coeficientes y variables. La rama voting promedia las salidas de los componentes en escala log. Los casos de paridad comprueban esta implementación frente al modelo de referencia: traducir el código exige verificar equivalencia, además de mostrar que se ejecuta.

Ejecución remota verificada en Google Colab

Figura 8

Entorno remoto y verificación de los archivos de entrada



Nota. Captura real de la primera celda ejecutada en un servidor de Google Colab, desde su extensión oficial para VS Code. La salida identifica Linux, Python 3.13.16, google-colab 1.0.0 y los hashes verificados. La ejecución comenzó el 24/10/2026 a las 14:23, hora de Colombia.

Las cinco celdas de código de Avances_IV_YouTube_Colab_Ejecutado.ipynb terminaron sin errores. Se utilizó un servidor CPU de Google Colab seleccionado en VS Code; el editor fue el cliente y el cómputo se realizó en Google. Este uso está contemplado por la extensión oficial (Google, s. f.-b).

Se guardaron las salidas del cuaderno, las métricas y las verificaciones. El archivo cloud_provenance.json registra inicio y fin UTC, versiones y revisión de las fuentes. El ZIP recuperado se comprobó con SHA-256 antes de integrarlo al proyecto. La copia local anterior se conserva como antecedente separado.

Comparación de la reproducción entre entornos

Tabla 8

Resultados iniciales y reproducción en Google Colab

Medición	Python local	Google Colab
Ensamble congelado: RMSE log	0,559311	0,559311
Solo comentarios congelado: RMSE log	2,101733	2,101733
HGB reajustado: RMSE log	0,583084	0,580889
Estrés: HGB fijo, RMSE log	0,702289	0,714865
Estrés: ensamble fijo, RMSE log	0,749735	0,757846
Inferencia: mediana de latencia, ms	8,72	2,35

Nota. Fuentes: results_iv/ y results_colab/. Las Tablas 3 a 7 conservan la ejecución local inicial. Local: Python 3.12.14, NumPy 2.5.4, pandas 3.0.1 y Scikit-learn 1.9.1. Colab: Python 3.13.16, NumPy 2.1.3, pandas 2.2.3 y Scikit-learn 1.6.1.

La inferencia del artefacto congelado conservó sus métricas hasta precisión numérica: RMSE log de 0,559311, MAE de 0,421376 y R^2 de 0,946111. Los modelos que se reajustan presentan variaciones entre entornos. Como cambiaron plataforma y versiones, esta comparación no aísla el factor responsable; muestra la necesidad de registrar el ambiente además de fijar datos, código y semillas.

En Colab también pasaron los 50 casos de paridad, con error máximo de 3,55 × 10^-15, y las seis entradas inválidas fueron rechazadas. La latencia mediana fue 2,35 ms y el percentil 95 fue 2,81 ms, sin incluir red ni arranque. El intervalo apareado de RMSE frente a HGB fue [-0,0578; 0,0085] e incluyó cero; HGB siguió superando al ensamble en el estrés por publicación. Se mantienen, por tanto, las precauciones de interpretación de la evaluación inicial.

Lecciones aprendidas y aplicación posterior

Tabla 9

Aprendizajes derivados de los resultados y acciones aplicables

Aprendizaje	Fundamento observado	Aplicación concreta
Definir la predicción antes de modelar	Interacciones y vistas describen el mismo periodo acumulado.	Para un horizonte de 7 o 30 días, fijar fecha de corte, variables disponibles y vistas posteriores.
Examinar incertidumbre y régimen	IC apareado incluye cero y HGB gana en el corte por publicación.	Conservar ambas alternativas; decidir con un conjunto externo definido antes de comparar.
Evaluar el costo en la escala de uso	MAE de Q4 de 44,46 M pese a buen R^2 global en log.	Acordar tolerancias por rango y evitar decisiones basadas en un conteo puntual sin incertidumbre.
Validar artefactos además de modelos	Paridad cercana a precisión de máquina y contrato verificable.	Añadir los 50 casos a cada revisión del artefacto; bloquear despliegues si fallan.
Planear colaboración trazable	El repositorio centraliza la revisión técnica en una cuenta.	Asignar issues, registrar decisiones y requerir revisión cruzada con cuentas reales del equipo.

Nota. Las acciones son propuestas de continuidad; no se presentan como actividades ya ejecutadas ni como efectos medidos.

Para una próxima iteración, la prioridad es obtener datos adecuados al uso, antes de ampliar la complejidad del modelo. Se necesitan identificador de canal, fecha de captura, observaciones posteriores y un protocolo de separación por canal y tiempo. La recolección debe reducir exposición innecesaria de usuarios: almacenar agregados y evitar publicar identificadores personales de comentaristas.

Reflexión sobre el trabajo colaborativo

El equipo está integrado por Cristian Camilo Alarcon Delgadillo, Bryan Arley Saenz Cortes y Jonathan David Lancheros Bello, nombres confirmados para esta entrega. La continuidad de los informes permite compartir un problema, una base depurada y criterios de evaluación. El beneficio de esa continuidad es que cada etapa puede confrontar afirmaciones anteriores con evidencia adicional, sin reiniciar el proyecto ni perder la referencia de comparación.

La evidencia técnica disponible consiste en los informes colectivos, el código, los artefactos, las capturas del entorno y el historial del repositorio asociado a la cuenta Camilo19P8. Estos registros documentan productos y revisiones de esa cuenta, pero no demuestran quién realizó cada tarea entre los tres integrantes. No se suministraron actas, mensajes de coordinación ni una distribución de funciones confirmada. Por eso no se atribuyen tareas individuales ni se afirma una revisión cruzada excepcional sin respaldo.

La principal lección de colaboración es que la autoría compartida y la trazabilidad de contribuciones son dimensiones distintas. Para mejorar el proceso, el equipo puede acordar una revisión metodológica, otra de reproducción y otra editorial, registradas como issues y solicitudes de cambio con cuentas reales. Cada revisión debería incluir una decisión, una evidencia y un responsable. Este mecanismo permitiría detectar discrepancias de cifras, problemas de interpretación y errores de enlaces antes de entregar.

En el cierre actual, las decisiones quedan concentradas en archivos verificables: métricas CSV, predicciones por video, resumen JSON y código versionado. Esto facilita que los tres autores discutan resultados concretos y reproduzcan el análisis. La documentación individual de aportes sigue siendo una limitación de evidencia y no se sustituye con roles propuestos o commits atribuidos a otras personas.

Producto entregado y reproducción

Repositorio del proyecto en GitHub

Abrir el cuaderno en Google Colab

Prototipo interactivo del proyecto

El repositorio contiene el código, el artefacto congelado, referencias de III y resultados de IV. El cuaderno descarga una revisión fija de las fuentes, verifica la identidad de los archivos de datos y permite repetir la evaluación. Las salidas identifican el entorno real. Además de la verificación local inicial, se ejecutó una copia en un servidor de Google Colab mediante la extensión oficial Google.colab para VS Code. El cuaderno conserva las salidas remotas y el registro del entorno en results_colab/cloud_provenance.json. Colab puede abrir cuadernos desde GitHub, pero sus archivos y máquina de ejecución no se comparten automáticamente con el notebook (Google, s. f.-a).

El flujo de reproducción es abrir el cuaderno, ejecutar sus celdas en orden y revisar los mensajes de descarga, métricas y verificaciones. No requiere credenciales de Kaggle dentro del código. El paquete también permite usar Python local mediante requirements.txt, download_data.py y final_evaluation.py. Las versiones iniciales registradas son Python 3.12.14, NumPy 2.5.4, pandas 3.0.1 y Scikit-learn 1.9.1; los reajustes de referencia pueden variar con otras versiones. La inferencia congelada incluye casos de paridad para identificar discrepancias.

El prototipo corresponde al despliegue de Avances III y mantiene acceso privado; el enlace no asegura acceso anónimo del docente. Para revisión sin esa autorización, el repositorio público y el cuaderno contienen la lógica reproducible. La interfaz sirve como demostración del producto, mientras que las métricas del informe proceden del protocolo de evaluación y no de consultas manuales aisladas.

Conclusiones

El proyecto alcanzó un producto académico integrado: preparación de videos y comentarios, variantes de PLN, selección controlada, inferencia portable, prototipo y un repositorio reproducible. Respecto del diseño de referencia, el avance principal es pasar de explorar asociaciones a contrastar alternativas y documentar qué capacidades respalda la evidencia. La estimación contemporánea está implementada; el pronóstico futuro y la operación productiva centralizada permanecen fuera de lo validado.

El ensamble congelado obtuvo el menor error de la comparación retrospectiva, con RMSE log de 0,5593 frente a 0,5831 de HGB. Esta ventaja descriptiva es moderada: su intervalo apareado incluye cero y el orden se invierte en el estrés por publicación. En consecuencia, el ensamble es una alternativa operativa sustentada por el desarrollo previo, pero los resultados de IV no justifican declararlo universalmente superior.

El texto aislado aporta señal sobre la mediana, aunque su precisión queda por debajo de los modelos con interacciones. El resultado invita a estudiar el lenguaje como información complementaria y a evitar conclusiones causales sobre comentarios o sentimiento. Los errores de millones de vistas en la cola superior también muestran por qué un R^2 global alto no basta para decisiones que requieran conteos exactos.

Las verificaciones reducen el riesgo de divergencia entre el modelo y su implementación, y la publicación del código facilita revisión y reproducción. Los siguientes pasos requieren nuevas observaciones, evaluación por canal y tiempo, seguimiento de resultados reales y contribuciones del equipo registradas con evidencia. Esas mejoras responden a limitaciones identificadas, sin convertir planes de trabajo en logros ya obtenidos.

Referencias

Alarcon Delgadillo, C. C., Saenz Cortes, B. A., & Lancheros Bello, J. D. (2026a). *Proyecto estadísticas de YouTube: Avances II* [Informe académico no publicado]. Universidad de Cundinamarca.

Alarcon Delgadillo, C. C., Saenz Cortes, B. A., & Lancheros Bello, J. D. (2026b). *Proyecto estadísticas de YouTube Avances III* [Informe académico no publicado]. Universidad de Cundinamarca.

Alarcon Delgadillo, C. C., Saenz Cortes, B. A., & Lancheros Bello, J. D. (2026c). *Estadísticas de YouTube con procesamiento de lenguaje natural* [Código fuente]. GitHub. https://github.com/Camilo19P8/youtube-estadisticas-nlp

Google. (s. f.-a). *Frequently asked questions*. Colaboratory. https://research.google.com/colaboratory/faq.html

Google. (s. f.-b). *Google Colab VS Code extension* [Software]. Visual Studio Marketplace. https://marketplace.visualstudio.com/items?itemName=Google.colab

Patil, A. (s. f.). *YouTube statistics* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/advaypatil/youtube-statistics

Scikit-learn. (s. f.). *Cross-validation: Evaluating estimator performance*. https://scikit-learn.org/stable/modules/cross_validation.html

Universidad de Cundinamarca. (2026). *REA 2 y tarea: Informe de trabajo «Proyecto estadísticas de YouTube Avances IV»* [Material de curso, acceso restringido]. Plataforma de Posgrado. Actividad Avances IV